



TECH CHALLENGE • FASE 2

Pipeline híbrida para análise da alfabetização no Brasil

Meta nacional e dispersão municipal

Uma criança é considerada alfabetizada quando atinge 743 pontos na escala de leitura do Saeb, ao fim do 2º ano do ensino fundamental.

O Compromisso Nacional tem como objetivo alfabetizar todas as crianças.

80%

a meta pactuada para 2030, com trajetória anual publicada pelo Inep (59,9% em 2024, subindo até 80% em 2030)

62,8%

é onde está hoje o município médio da rede municipal

■ 22,9


pontos separam a região com maior taxa (Centro-Oeste, 72,3%) da menor (Norte, 49,4%)

■ 95,6

pontos separam o melhor município (100%) do pior (4,4%)

■ 29,0%

dos municípios do Norte têm menos de 40% das crianças alfabetizadas. No Sudeste, são 1,9%



Distribuição da taxa por município e por região

Mas o município médio não existe. As taxas municipais vão de 4,4% a 100%. Para agir, é preciso saber de quais municípios se trata — e essa resposta estava espalhada em seis bases diferentes.

Seis fontes sem chave comum

A mesma rede de ensino aparecia como número numa base e como texto em outra. O de-para entre as duas não estava publicado em lugar nenhum.


FONTE	GRÃO	IDENTIFICA A REDE
Microdados de aluno	1 linha por aluno	código numérico
Indicador por município	ano × município × rede × série	código numérico
Indicador por UF	ano × UF × rede × série	código numérico
Meta por município	ano × município × rede	texto
Meta por UF e Brasil	ano × UF × rede	texto
Território (IBGE)	1 linha por município	não se aplica

O território vinha apenas como código IBGE de sete dígitos. Sem nome de município, UF e região, nenhum recorte territorial era possível — foi preciso buscar na API do IBGE.

O de-para da rede foi deduzido dos próprios dados e validado em 10.584 comparações, com 3 divergências. Sem esse passo, meta e resultado nunca se encontram.

Arquitetura do fluxo de dados

Do arquivo bruto à decisão, sem passo manual.



Stack e justificativa de cada escolha

Cada peça responde a uma exigência do desenho — nenhuma entrou por preferência.

Free Edition

Databricks

Lakehouse gerenciado, com camada gratuita — nuvem sem custo para o projeto

armazenamento

Delta Lake

Transações ACID, MERGE e histórico versionado sobre Parquet aberto

governança

Unity Catalog

Catálogo, permissões e linhagem no mesmo lugar em que o dado vive

eventos

Structured Streaming

O mesmo motor do lote processa o streaming — uma base de código, não duas

processamento

PySpark

Escala para 3,87 milhões de linhas sem sair da linguagem do time

Camadas Bronze, Silver e Gold: propósito e inventário

31 tabelas | 8,05 M linhas

Bronze guarda

Como veio da fonte, sem descarte, com linhagem por registro. Se a regra mudar, o reprocessamento parte daqui.

10 tabelas · 3.909.698

aluno	3.867.999
indicador_municipio	23.995
meta_municipio	10.704
dim_municipio_ibge	5.571
indicador_uf	145
meta_uf	54
dim_uf_ibge	27
meta_brasil	3
avaliacao_stream	1.132
avaliacao_dlq	68

Silver integra

Tipos padronizados, chaves normalizadas, domínio decodificado e as seis fontes integradas. Nunca sobrescreve a Bronze.

12 tabelas · 4.083.013

fato_alfabetizacao_municipio	23.995
fato_aluno	3.867.999
fato_distribuicao_nivel	112.032
dim_meta_municipio	37.344
fato_indicador_municipio	23.995
fato_participacao_municipio	10.584
dim_municipio	5.571
dim_meta_uf	180
fato_indicador_uf	145
fato_avaliacao_stream	1.132
dim_uf	27
alerta_stream	9

Gold entrega

Nove tabelas, cada uma respondendo uma pergunta que o gestor faz.

9 tabelas · 60.997

gold_indicador_municipio	23.995
gold_evolucao_temporal	12.650
gold_perfil_aluno_municipio	12.431
gold_features_ml	5.448
gold_priorizacao_municipio	5.448
gold_distribuicao_niveis	693
gold_meta_vs_realizado	147
gold_ranking_uf	145
gold_avaliacao_streaming	40

Qualidade e monitoramento

SEIS DIMENSÕES VERIFICADAS

Compleitude	há campo obrigatório vazio?
Unicidade	o grão declarado tem duplicata?
Validade	o valor está no domínio e na faixa esperada?
Relacionamento	toda chave existe na tabela de referência?
Consistência	as tabelas concordam entre si?
Atualidade	o dado é do ciclo que deveria ser?

37 verificações a cada rodada · 32 na Bronze, 5 na Gold · ERROR interrompe, WARNING registra

O que é medido

duração · linhas de entrada · linhas de saída · linhas rejeitadas de cada etapa. São as quatro grandezas que respondem se a esteira está lenta, se está perdendo dado e se o volume mudou sem aviso.

Onde fica

Duas tabelas Delta no Unity Catalog: uma linha por etapa executada, uma por alerta emitido. Cada execução carrega um identificador próprio, então comparar a rodada de hoje com a da semana passada é uma consulta SQL.

O que acontece quando falha

A etapa é marcada com status FALHA, um alerta de severidade alta é gravado, e a exceção sobe — a tarefa do Lakeflow para em vez de propagar dado ruim adiante. O erro é registrado antes de interromper a execução.

Perguntas respondidas na camada Gold

A pipeline importa porque transforma perguntas que levavam semanas em consultas de segundos — e cada uma delas muda uma decisão.

A PERGUNTA	RESPONDE EM	O QUE ISSO MUDA
Quais municípios estão fora da rota da própria meta?	gold_indicador_municipio	direciona recurso para quem está atrás da meta que assinou, não da média nacional
Quem melhorou e quem piorou entre os ciclos?	gold_evolucao_temporal	separa quem precisa de apoio de quem precisa de continuidade
Quanto cada região precisa avançar por ano até 2030?	gold_indicador_municipio	transforma uma meta de sete anos em compromisso anual verificável
Qual estado concentra os casos críticos?	gold_meta_vs_realizado	permite negociar apoio federal com evidência, não com percepção
A dificuldade está nos níveis mais baixos ou é difusa?	gold_distribuicao_niveis	indica se a política é de alfabetização ou de aprofundamento

Antes, cada uma dessas respostas exigia cruzar planilhas à mão, sem rastro de como o número foi produzido. Agora é uma consulta SQL, reproduzível e auditável.

Aplicações de IA habilitadas pela Gold

A camada analítica não precisa de preparação adicional para alimentar modelos — estas três partem das tabelas como elas estão hoje.

01

Prever quem vai ficar para trás

gold_features_ml

FARIA • estimar a taxa do próximo ciclo antes da avaliação acontecer

MUDA • agir no ano corrente em vez de reagir dois anos depois, quando o resultado sai

02

Agrupar por perfil, não por ranking

gold_indicador_municipio •
gold_distribuicao_niveis

FARIA • identificar grupos de municípios com o mesmo tipo de dificuldade, sem supervisão

MUDA • dificuldade difusa pede intervenção diferente de dificuldade concentrada nos níveis iniciais

03

Ordenar a fila de intervenção

gold_priorizacao_municipio

FARIA • combinar distância da meta, trajetória e posição relativa num índice único

MUDA • uma fila auditável, em que cada posição é explicável para quem ficou de fora

AINDA DESTRAVA,
SEM MUDAR O
ESQUEMA

Anomalia sobre
gold_avaliacao_streaming,
sinalizando queda durante a prova

Previsão de trajetória em vez de ponto
único, com mais ciclos publicados

Censo Escolar e FUNDEB em
gold_features_ml, o passo até o
"por quê"

O que fica

PRONTO

Seis fontes integradas numa chave comum, com o indicador oficial reproduzido a partir do grão de aluno

Camada analítica em nove tabelas, consultável por SQL

Uma fila de municípios em prioridade crítica, com o quanto falta em cada um

PRÓXIMO

Censo Escolar, PNAD e FUNDEB entram pela Bronze, sem refazer nada acima

Previsão de trajetória, quando houver mais ciclos publicados



Obrigado pela atenção
